



Aplicação da Metaheurística Ant Colony Optimization (ACO) para Resolver o Problema de Roteamento de Veículos (VRP)

Kawan Oliveira¹

Departamento de Engenharia de Computação e Automação, Universidade Federal do Rio Grande do Norte

Resumo:

Este relatório aborda o Problema de Roteamento de Veículos (VRP), um desafio clássico de otimização logística cuja meta é determinar rotas eficientes para uma frota de veículos atender a diversos clientes, minimizando a distância percorrida e respeitando restrições como capacidade de carga e tempo de rota. O VRP é uma generalização do Problema do Caixeiro Viajante (TSP), o que justifica a escolha da metaheurística Ant Colony Optimization (ACO) como abordagem de solução, dada sua eficácia comprovada em problemas baseados em grafos e sua capacidade de adaptação a restrições do VRP.

A ACO foi aplicada ao problema com sucesso, gerando rotas otimizadas que agrupam clientes próximos, evidenciando boa performance em cenários onde a capacidade da frota é suficiente. No entanto, limitações foram observadas em casos com capacidade insuficiente: o algoritmo não prioriza estrategicamente a cobertura máxima de clientes, uma vez que baseia suas decisões em critérios probabilísticos locais, como feromônio e distância. Conclui-se que a ACO é uma abordagem viável e eficiente para o VRP, mas que seu desempenho pode ser aprimorado com ajustes no modelo para lidar melhor com restrições operacionais severas e ambientes mais exigentes.

Palavras Chave: Metaheurística, Algoritmo, Otimização.

1 Introdução

O Vehicle Routing Problem (VRP), ou Problema de Roteamento de Veículos, é um problemas com aplicações diretas em logística, transporte e planejamento de operações. Sua formulação descreve situações práticas em que uma frota de veículos deve realizar entregas ou coletas partindo de um ou mais depósitos para atender a um conjunto de clientes distribuídos geograficamente.

Este problema está no cerne de operações logísticas de empresas como transportadoras, redes de distribuição de produtos, serviços postais (como os Correios) e grandes varejistas (como a Amazon), onde o objetivo é reduzir custos operacionais e aumentar a eficiência do uso da frota. O VRP busca determinar o conjunto de rotas mais eficientes, de modo que todos os clientes sejam atendidos e a distância total percorrida pelos veículos seja minimizada, respeitando as restrições impostas por capacidade de carga, número de veículos, tempo máximo de rota, entre outras.

1.1 Relação com o Problema do Caixeiro Viajante (TSP)

O VRP é uma generalização natural do clássico *Travelling Salesman Problem* (TSP), ou Problema do Caixeiro Viajante. No TSP, o objetivo é encontrar o caminho de menor custo que permita a um único agente (vendedor) visitar um conjunto de cidades exatamente uma vez e retornar ao ponto de partida. Embora sua formulação seja simples, o TSP é um problema NP-difícil, com complexidade exponencial em relação ao número de cidades. O VRP herda essa complexidade e a amplia ao incluir múltiplos veículos e diversas restrições logísticas adicionais.

Ao passo que o TSP lida com a otimização de uma única rota, o VRP exige a construção simultânea de múltiplas rotas interdependentes, todas respeitando restrições específicas. Cada uma dessas rotas pode ser encarada como um "mini-TSP", cuja solução contribui para o desempenho global do sistema de entregas.

1.2 Importância Prática e Relevância Teórica

A importância do VRP vai além de sua aplicação prática. Ele serve como base para o estudo e desenvolvimento de diversas estratégias de otimização, principalmente no campo das metaheurísticas. Dado seu caráter NP-difícil, a busca por soluções ótimas exatas é muitas vezes impraticável em larga escala. Nesse contexto, técnicas como Algoritmos Genéticos, Simulated Annealing, Enxame de Partículas (PSO) e, especialmente, Ant Colony Optimization (ACO), têm se mostrado eficazes para encontrar boas soluções em tempo razoável.

O VRP também apresenta uma base sólida para avaliação comparativa de algoritmos de otimização, visto que o seu "problema base" é um dos mais famosos de todos (TSP).

Para ilustrar de forma clara a relação entre os dois problemas, pode-se fazer a seguinte comparação:

- TSP (Travelling Salesman Problem): Um único agente, uma única rota, objetivo de minimizar a distância total ao visitar todos os pontos e retornar à origem.
- VRP (Vehicle Routing Problem): Múltiplos agentes (veículos), múltiplas rotas, objetivo de minimizar o custo total atendendo todos os clientes, com várias restrições logísticas.

Em termos práticos, resolver o TSP equivale a resolver uma versão extremamente simplificada do VRP, com apenas um veículo, sem restrições de capacidade, tempo ou demanda variável. Essa relação justifica a adaptação e reutilização de estratégias computacionais originalmente desenvolvidas para o TSP na resolução de instâncias mais complexas do VRP.

2 Discussão Sobre a Metaheurística

Para abordar o Problema de Roteamento de Veículos (VRP) neste trabalho, optou-se pela utilização da metaheurística *Ant Colony Optimization* (ACO), ou Otimização por Colônia de Formigas. Essa técnica foi originalmente proposta por Marco Dorigo na década

de 90 para resolver o *Travelling Salesman Problem* (TSP) e se inspira no comportamento cooperativo de colônias de formigas na natureza, particularmente em sua capacidade de encontrar caminhos eficientes entre o ninho e fontes de alimento por meio de trilhas de feromônio.

2.1 Justificativa da Escolha da ACO

A ACO mostra-se uma abordagem natural e eficaz para o VRP por diversas razões. A ACO foi desenvolvida inicialmente para resolver o TSP, e como o VRP é uma generalização do TSP, a adaptação da técnica ocorre de forma conceitualmente fluida. Além disso, o VRP é modelado como um grafo completo, onde os nós representam clientes e depósitos, e as arestas representam distâncias ou custos de deslocamento. A estrutura gráfica do problema está diretamente alinhada com o funcionamento da ACO. A ACO permite a fácil incorporação de restrições específicas do VRP, como capacidade de carga dos veículos, janelas de tempo, limites de distância, entre outras condições operacionais. Por ser baseada em busca estocástica e construção iterativa de soluções, a ACO possui um bom equilíbrio entre exploração de novas soluções e intensificação de trilhas promissoras. Isso evita que o algoritmo fique preso em mínimos locais, o que é particularmente importante em problemas altamente combinatórios como o VRP.

2.2 Mecanismo de Funcionamento da ACO no VRP

A implementação do algoritmo segue a estrutura clássica da ACO, com adaptações específicas para contemplar as restrições do VRP. Cada agente (formiga) simula a construção de uma solução viável, ou seja, um conjunto de rotas para veículos que atendem a todos os clientes respeitando os limites de capacidade.

A construção da solução ocorre de forma incremental. Em cada passo, a formiga seleciona o próximo cliente a ser visitado com base em uma combinação de dois fatores:

- Feromônio (τ_{ij}): Representa a experiência acumulada em cada aresta, indicando a atratividade da transição de um ponto i para um ponto j com base nas soluções anteriores.
- Heurística (η_{ij}): Representa uma medida local de qualidade, geralmente definida como o inverso da distância entre os pontos i e j:

$$\eta_{ij} = \frac{1}{\text{distância}_{ij}} \tag{1}$$

A probabilidade de uma formiga a escolher o cliente j como próximo ponto, estando no cliente i, é calculada por:

$$p_{ij}^{a} = \frac{[\tau_{ij}]^{\alpha} \cdot [\eta_{ij}]^{\beta}}{\sum\limits_{k \in \text{clientes n\~{a}o visitados}} [\tau_{ik}]^{\alpha} \cdot [\eta_{ik}]^{\beta}}$$
(2)

onde:

- τ_{ij} é a quantidade de feromônio na aresta $i \rightarrow j$;
- η_{ij} é o valor heurístico (visibilidade), definido como o inverso da distância entre i e j;
- α e β são parâmetros que controlam o peso relativo do feromônio e da heurística na decisão;
- O denominador é uma normalização sobre todos os clientes ainda não visitados.

Quando a soma da demanda acumulada em uma rota atinge a capacidade máxima do veículo, a formiga é forçada a retornar ao depósito e iniciar uma nova rota, até que todos os clientes sejam atendidos (ou até o ponto em que seja impossível atender mais clientes dentro das restrições impostas).

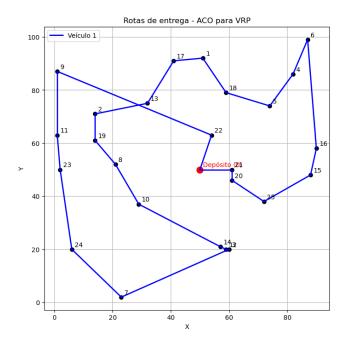


Figure 1. Exemplo de implementação de ACO para o problema de VSP com 1 Veículo, assemelhando-se ao problema do caixeiro viajante

2.3 Atualização do Feromônio

Após todas as formigas completarem a construção de suas soluções, ocorre a etapa de atualização dos níveis de feromônio. Nessa fase, o feromônio é evaporado parcialmente em todas as arestas, o que permite a diversificação da busca e evita a estagnação precoce:

$$\tau_{ij} \leftarrow (1 - \rho) \cdot \tau_{ij} \tag{3}$$

onde $\rho \in (0, 1)$ representa a taxa de evaporação do feromônio.

Em seguida, as melhores soluções (ou a melhor entre todas) reforçam as trilhas utilizadas, depositando uma quantidade proporcional à qualidade da solução (normalmente inversamente proporcional à distância total percorrida):

$$\tau_{ij} \leftarrow \tau_{ij} + \Delta \tau_{ij} \tag{4}$$

2.4 Exploração versus Intensificação

A ACO equilibra dois processos fundamentais para metaheurísticas:

- Exploração: Permite que formigas testem novas combinações de rotas ao longo das iterações, aumentando a diversidade do conjunto de soluções geradas.
- Intensificação: O reforço das melhores trilhas promove a reutilização de caminhos promissores já descobertos, guiando a busca na direção de soluções cada vez mais refinadas.

Esse equilíbrio é o que faz basicamente o desempenho do algoritmo, especialmente em problemas como o VRP, onde a complexidade cresce rapidamente com o número de clientes e veículos.

3 Resultados Obtidos

A aplicação da metaheurística Ant Colony Optimization (ACO) ao Problema de Roteamento de Veículos (VRP) proporcionou a geração de soluções viáveis para a formação de rotas, respeitando restrições operacionais e buscando a minimização da distância total percorrida pelos veículos.

O cenário de teste considerado foi composto por uma frota de três veículos, cada um com capacidade máxima de 50 unidades, e um conjunto de 25 clientes, cada qual com uma demanda fixa de 10 unidades. Com isso, a capacidade total da frota (150 unidades) é inferior à demanda agregada (250 unidades), o que naturalmente implica que nem todos os clientes podem ser atendidos em uma única execução do algoritmo. Esse fator estabelece uma limitação estrutural do problema, servindo como ponto de avaliação da eficiência da estratégia adotada pelo ACO.

3.1 Análise dos Resultados Gerados

As rotas construídas pelas formigas ao longo das iterações refletem a atuação conjunta de dois fatores centrais do algoritmo: a quantidade de feromônio acumulada nas arestas e a visibilidade heurística, baseada na proximidade geográfica entre os pontos. Como resultado, observou-se que os clientes tendem a ser agrupados em subconjuntos espacialmente próximos, tanto entre si quanto em relação ao depósito, formando rotas localmente eficientes.

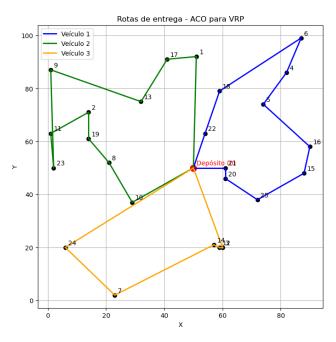


Figure 2. Exemplo de implementação de ACO para o problema de VSP com 3 Veículos

Em um caso excepcional executado para testar o comportamento onde os veículos juntos não conseguissem comportar toda a demanda total, ainda que não tenha sido possível atender à totalidade dos clientes — o que já era esperado dadas as restrições

de capacidade —, as soluções obtidas indicam que o ACO é eficaz na construção de rotas otimizadas do ponto de vista da distância percorrida. Isso demonstra o bom desempenho do algoritmo na formação de soluções parciais viáveis e coerentes com os objetivos da função de custo.

3.2 Limitações Observadas

Durante a análise dos resultados, algumas limitações importantes do algoritmo foram evidenciadas. Por tratar-se de uma abordagem metaheurística com natureza estocástica, o ACO não garante a cobertura completa da demanda nem a otimização do número de clientes atendidos em situações com recursos insuficientes.

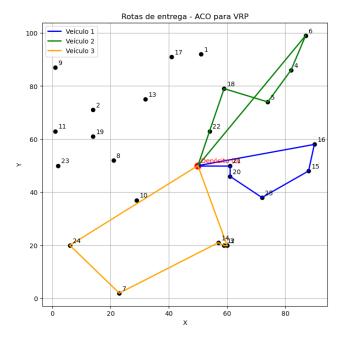


Figure 3. Exemplo de implementação de ACO para o problema de VSP com 3 Veículos onde os mesmos não conseguem suprir toda a demanda

Além disso, a escolha dos próximos clientes a serem inseridos em uma rota é realizada com base em um critério probabilístico, que leva em conta a intensidade do feromônio e a visibilidade heurística, sem incorporar diretamente um mecanismo determinístico de maximização da cobertura ou de priorização de clientes mais vantajosos do ponto de vista logístico.

Esse comportamento pode resultar em soluções nas quais os veículos completam suas rotas com combinações de clientes geograficamente próximas, mas que não necessariamente representam a alocação mais estratégica ou eficiente possível. Em outras palavras, o algoritmo tende a formar rotas boas em nível local, sem garantir uma visão global que maximize a utilização da capacidade total da frota.

3.3 Comportamento Esperado vs. Observado

Inicialmente, esperava-se que o algoritmo distribuísse a carga entre os veículos de maneira a maximizar o número de entregas dentro da capacidade disponível, otimizando tanto a distância quanto a cobertura. Contudo, o comportamento observado revela uma priorização de agrupamentos locais eficientes, com menor atenção

à cobertura total.

Embora as soluções apresentadas demonstrem boa performance em termos de distância percorrida, elas nem sempre correspondem às configurações ideais no que diz respeito à quantidade de clientes atendidos. Essa limitação reflete a ausência, no modelo utilizado, de um componente explícito de maximização de cobertura ou seleção estratégica de clientes.

4 Comentários e Conclusões

Os experimentos realizados ao longo deste trabalho demonstraram que a metaheurística *Ant Colony Optimization* (ACO) é uma abordagem viável, eficiente e conceitualmente alinhada com o escopo do Problema de Roteamento de Veículos (VRP), especialmente em cenários onde a capacidade da frota é suficiente para atender integralmente à demanda dos clientes.

Em tais configurações favoráveis, o algoritmo conseguiu gerar soluções que respeitam as restrições operacionais impostas (como capacidade dos veículos e número de clientes), resultando em rotas curtas, bem estruturadas e com baixo custo computacional. Esse desempenho positivo evidencia o poder do ACO na construção iterativa de caminhos otimizados, guiados pela interação entre o feromônio e as heurísticas locais, características centrais do modelo.

Entretanto, em cenários mais restritivos — como aqueles em que a capacidade total da frota é inferior à demanda agregada dos clientes — o comportamento do algoritmo revelou certas limitações. Observou-se que o ACO, por sua natureza estocástica e descentralizada, não garante a maximização da cobertura de clientes. Em vez disso, tende a formar rotas otimizadas localmente, favorecendo grupos de clientes geograficamente próximos ao invés de priorizar aqueles cuja entrega traria maior benefício estratégico para o sistema como um todo.

Esse tipo de comportamento evidencia uma limitação comum das metaheurísticas: embora sejam eficazes em encontrar boas soluções dentro de seus domínios de aplicação, seu desempenho pode deteriorar quando são utilizadas em problemas cujas características não estão integralmente contempladas em seu modelo original. No caso do ACO, a ausência de um critério explícito de maximização da cobertura, ou de priorização estratégica na escolha dos clientes, impacta diretamente a eficiência da solução final em ambientes com recursos escassos.

Embora não garanta a obtenção da solução ótima global, a ACO é capaz de produzir soluções de boa qualidade em tempos computacionais razoáveis, sendo uma alternativa atrativa para aplicações práticas e estudos acadêmicos. Ainda assim, a ACO se mostra uma ferramenta poderosa para problemas combinatórios, oferecendo uma base sólida para soluções de qualidade em aplicações práticas e acadêmicas.

Em suma, a aplicação do ACO ao VRP mostrou-se promissora, mas também revelou oportunidades claras de evolução. Com as devidas adaptações, o ACO pode ser uma ferramenta ainda mais robusta para enfrentar problemas reais de roteamento em ambientes logísticos complexos e restritos.